

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Departamento de Computación

CC3084 – Data Science

Sección 40

Ing. Erick Marroquín



Míneria de texto y análisis de sentimientos

Laboratorio No. 5

Angie Nadissa Vela López 23764

Cristian Sebastián Túnchez Castellanos, 231359

GUATEMALA, 30 de agosto de 2026

Datos y análisis exploratorio

Fuente y alcance

El dataset proviene de la competencia Natural Language Processing with Disaster Tweets de Kaggle. train.csv contiene 7,613 tweets con cinco variables: id, keyword, location, text y target. El conjunto completo descargado también incluye 3,263 observaciones en test.csv, para un total de 10,876 registros de competencia. Sin embargo, test.csv no posee target; por esa razón, los resultados descriptivos por clase y las métricas se calcularon únicamente con train.csv.

Tabla 1. Resumen descriptivo de train.csv

Elemento	Resultado
Observaciones etiquetadas	7,613
Columnas	5
Tweets target = 0	4,342 (57.0%)
Tweets target = 1	3,271 (43.0%)
Location faltante	2,533 (33.27%)
Keyword faltante	61 (0.80%)
Filas duplicadas completas	0
Textos duplicados	110

La distribución objetivo presenta una diferencia moderada, no extrema. La clase 0 representa 57% y la clase 1, 43%. Por ello, accuracy sigue siendo informativa, pero no basta: un modelo podría favorecer la clase mayoritaria. Se reportaron precision, recall y F1 para observar mejor el desempeño sobre los desastres reales.




Figura 1. Distribución de la variable objetivo.




Figura 2. Valores faltantes por columna.

1.2 Longitud, palabras clave y duplicados

Los tweets de target = 1 son ligeramente más largos. El promedio fue de 108.11 caracteres para desastres reales y 95.71 para la clase 0; en cantidad de palabras, los promedios fueron

15.17 y 14.70, respectivamente. La diferencia existe, pero las distribuciones se traslapan ampliamente, así que la longitud no permite clasificar por sí sola.




Figura 3. Distribución de longitud en caracteres y palabras por clase.

Las ubicaciones no se imputaron porque una tercera parte está ausente y el texto libre contiene formatos muy heterogéneos. Keyword presenta pocos faltantes y sirve para explorar los temas, pero no se utilizó como entrada separada del clasificador principal. Tampoco se eliminaron los 110 textos duplicados: no son filas idénticas y pueden corresponder a usuarios o metadatos diferentes. Eliminarlos sin revisar su procedencia podría borrar recurrencias reales de mensajes difundidos durante una emergencia.

Preprocesamiento

Decisiones y pérdidas posibles

El preprocesamiento buscó reducir variaciones superficiales sin borrar señales propias de Twitter. Cada transformación se implementó en `src/preprocessing.py` y el resultado se regeneró en `data/processed/train_processed.csv`; el archivo crudo se conserva sin cambios.

Tabla 2. Decisiones principales de preprocesamiento

Operación	Qué resuelve	Decisión y costo
Minúsculas	Unifica variantes como Fire/fire.	Se pierde énfasis por mayúsculas; el beneficio de reducir vocabulario fue mayor.
URL → token_url	Evita aprender enlaces únicos.	Se conserva que existía un enlace, señal frecuente en noticias y reportes.

@usuario → token_user	Reduce miles de cuentas únicas.	Se pierde identidad; se conserva la presencia de una mención.
Hashtag sin #	Permite usar su palabra en el vocabulario.	Se pierde la marca de hashtag, pero no el contenido léxico.
Puntuación	Reduce ruido y facilita tokenización.	Puede perder intensidad; contracciones se preservan cuando es posible.
Números	Se conservan como tokens.	Evita borrar información como 911, años, cifras o magnitudes.
Emoji	Se transforma a token por código Unicode.	Conserva su presencia; se detectó mojibake que limita la recuperación.
Stopwords	Elimina palabras funcionales frecuentes.	Las negaciones no/not/never y contracciones negativas se conservan.
Stemming/lematización	No se aplicaron.	Se mantiene legibilidad y se evitan raíces artificiales o costo adicional.

Tokenización, stopwords y negaciones

La tokenización usa una expresión regular ajustada al corpus en inglés. Reconoce palabras, números, contracciones y los marcadores token_url y token_user. Las stopwords provienen de NLTK, pero se retira explícitamente de esa lista un conjunto de negaciones. Esta decisión es importante porque no fire, never happened o isn't real cambian el sentido de la frase; eliminar la negación dejaría únicamente el término asociado con desastre y aumentaría falsos positivos.

Emojis, emoticones y codificación

El pipeline no elimina emojis Unicode, los convierte en tokens estables. La auditoría encontró 0 emojis Unicode reconocidos, 64 emoticones ASCII y 5 casos de xD o corazones. También aparecieron 612 textos con secuencias sospechosas de mojibake (por ejemplo, Ŭs o Ŭ_ en lugar de apóstrofes o comillas), concentradas en unos pocos caracteres especiales mal codificados al origen. Esto indica que parte del contenido visual pudo dañarse antes de llegar al CSV. El impacto se limita principalmente a la lectura visual del texto y a la nube de palabras, donde esas secuencias pueden aparecer como tokens sueltos sin significado; en VADER el efecto es menor, porque el léxico evalúa palabras completas y las secuencias dañadas rara vez coinciden con entradas del diccionario, por lo que simplemente se ignoran.

en el cómputo del compound en vez de sesgarlo. Para no introducir una corrección incierta que pudiera alterar palabras válidas, se documentó el problema sin repararlo y VADER se aplicó sobre el texto original decodificado con `html.unescape`.

Stemming frente a lematización

El stemming recorta palabras mediante reglas y puede producir raíces que no son palabras completas; la lematización intenta devolver una forma canónica con apoyo lingüístico. En este corpus, los tweets son cortos, informales y principalmente en inglés. No aplicamos ninguna de las dos técnicas porque TF-IDF ya controla parte de la variación por frecuencia, el vocabulario obtenido fue interpretable y reducir formas podía unir términos con usos distintos.

Unigramas, bigramas y nubes de palabras

Unigramas

Un unigrama es un token considerado de manera individual. La frecuencia absoluta indica cuántas veces aparece; la frecuencia relativa por clase puede interpretarse como una estimación de $P(\text{palabra} \mid \text{clase})$, calculada dividiendo la frecuencia del término dentro de la clase entre el total de tokens de esa clase. Esta normalización facilita comparar clases con distinto número de tweets.

Tabla 3. Unigramas representativos por clase

Clase	Unigrama	Frecuencia
target = 0	token_url	2,204
target = 0	token_user	1,823
target = 0	like	254
target = 0	not	205
target = 0	new	171
target = 1	token_url	2,519
target = 1	token_user	889
target = 1	fire	182
target = 1	news	139
target = 1	disaster	121




Figura 4. Unigramas más frecuentes en target = 0 y target = 1.

token_url aparece mucho en ambas categorías y por sí solo discrimina poco, aunque es proporcionalmente más común en target = 1. token_user domina la clase 0 y puede reflejar conversación o interacción. En cambio, fire, disaster, suicide, california y police aparecen entre los términos destacados de target = 1 y describen eventos, lugares o actores más compatibles con noticias reales. Palabras como no se encuentran en ambas clases y necesitan contexto.

Bigramas

Los bigramas combinan dos tokens consecutivos y recuperan parte del orden perdido por la bolsa de palabras. Los resultados muestran que su principal aporte es desambiguar expresiones como: suicide bomber, northern california y oil spill son más informativos que sus palabras aisladas.

Tabla 4. Bigramas representativos por clase

Clase	Bigrama	Frecuencia
target = 1	suicide bomber	59
target = 1	northern california	41
target = 1	oil spill	38
target = 1	burning buildings	36
target = 1	suicide bombing	35

target = 0	token_user token_user	369
target = 0	token_url token_url	285
target = 0	via token_user	85




Figura 5. Bigramas más frecuentes en ambas clases.

Los bigramas de target = 0 están dominados por marcadores sociales y combinaciones repetidas, mientras que target = 1 contiene frases temáticas concretas.

¿Vale la pena explorar bigramas o trigramas?

Sí es bastante útil para interpretación, no para el desempeño del clasificador preliminar. Cualitativamente, los bigramas aportan contexto que el unigrama no captura por sí solo, suicide bomber, northern california y oil spill identifican eventos y lugares concretos, mientras que suicide o california aislados son más ambiguos. Sin embargo, al incorporarlos al vectorizador TF-IDF (Tabla 5), el F1 en prueba bajó de 0.7772 a 0.7723 y el accuracy de 0.8227 a 0.8188. La razón más probable es que los bigramas relevantes son poco frecuentes de forma individual, por lo que aportan menos señal estadística de la que agregan en dispersión y tamaño de vocabulario. No exploramos trigramas por la misma razón, con tweets de longitud promedio de 14 a 15 palabras, los trigramas tendrían aún menor frecuencia y mayor riesgo de sobreajuste. En síntesis, los bigramas se recomiendan como herramienta exploratoria y de lectura del corpus, pero no se incorporaron al modelo final.

Las nubes se construyeron con el texto preprocesado y la misma configuración para ambas clases. Su función es exploratoria: permiten reconocer rápidamente vocabulario dominante, pero no sustituyen las tablas de frecuencia porque el tamaño visual no muestra incertidumbre ni controla por el total de tokens.



División y representación TF-IDF

TF-IDF pondera cada término combinando TF, su frecuencia en un documento, e IDF, una medida que disminuye el peso de los términos presentes en muchos documentos. En forma resumida: $TF\text{-}IDF(t,d) = TF(t,d) \times \log(N / DF(t))$. Frente a una cuenta simple, resalta palabras relativamente características sin permitir que términos globalmente frecuentes dominen toda la representación. Se usaron $\min_df=2$, $\max_df=0.95$ y $\text{sublinear_tf}=\text{True}$.

Línea base y evaluación

Tabla 5. Resultados preliminares en prueba

Representación	Accuracy	Precision	Recall	F1
TF-IDF unigramas	0.8227	0.8441	0.7202	0.7772
TF-IDF uni+bigramas	0.8188	0.8387	0.7156	0.7723




Figura 7. Matrices de confusión de las dos representaciones TF-IDF.

El F1 es la media armónica entre precision y recall. Es relevante porque penaliza modelos que obtienen una de estas métricas a costa de la otra. La línea base identificó correctamente 471 desastres reales y omitió 183. Su precision de 0.8441 indica que la mayoría de las predicciones positivas fue correcta, mientras que el recall de 0.7202 muestra que todavía se pierden cerca de 28% de los desastres reales del conjunto de prueba.

Comparación y selección de candidatos

Tabla 6. Validación cruzada estratificada de cinco pliegues sobre entrenamiento

Clasificador	Representación	Accuracy	Precision	Recall	F1	DE F1
LogisticRegression	Unigramas	0.7980	0.8224	0.6763	0.7421	0.0135
LogisticRegression	Uni+bigramas	0.7970	0.8269	0.6679	0.7387	0.0160
LinearSVC	Unigramas	0.7829	0.7672	0.7111	0.7379	0.0156
MultinomialNB	Unigramas	0.7938	0.8264	0.6595	0.7333	0.0109

LinearSVC	Uni+bigramas	0.7791	0.7640	0.7035	0.7324	0.0182
MultinomialNB	Uni+bigramas	0.7918	0.8569	0.6194	0.7186	0.0167




Figura 8. Comparación de modelos mediante F1 de validación cruzada.

La regresión logística con unigramas obtuvo el mayor F1 promedio y además permite interpretar coeficientes. La diferencia con otras alternativas es pequeña, por lo que no se afirma que sea universalmente superior; se seleccionó porque lideró el criterio definido antes de abrir la prueba final. Random Forest y transformers no se incorporaron: el primero no es una opción natural para esta matriz dispersa y los segundos exceden la complejidad necesaria para el objetivo académico.

Interpretación del modelo

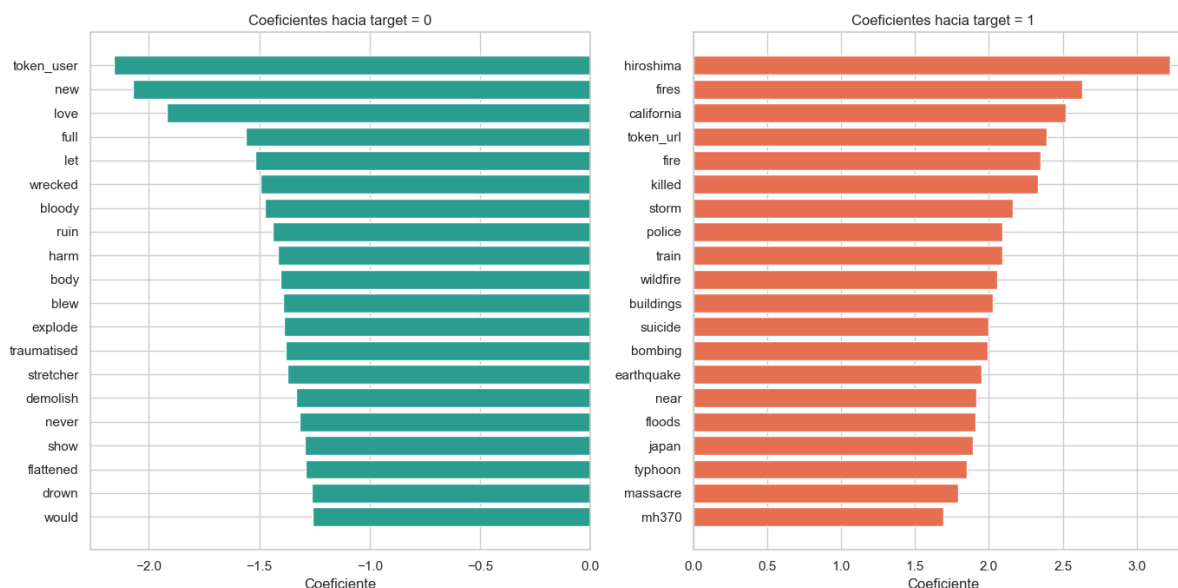


Figura 9. Términos con mayor peso hacia target = 0 y target = 1.

Los coeficientes positivos más altos incluyen hiroshima, fires, california, killing, fire, killed, storm, police, bombing y earthquake. Son términos compatibles con eventos, víctimas, localizaciones o coberturas noticiosas. Hacia target = 0 aparecen token_user, love, like, just y watched, que se relacionan más con interacción y lenguaje cotidiano. Algunos pesos requieren cautela: un nombre geográfico o una palabra dramática puede correlacionarse con la etiqueta por cómo fue construido el corpus, sin ser una regla causal.

Análisis de sentimientos

Método

Se utilizó VADER, un analizador léxico diseñado para texto breve de redes sociales. VADER devuelve proporciones de negatividad, neutralidad y positividad, además de compound, un puntaje normalizado entre -1 y 1. Se aplicaron los umbrales convencionales: compound ≤ -0.05 para negativo, compound ≥ 0.05 para positivo y el intervalo intermedio para neutral. El análisis se ejecutó sobre el texto original, no sobre el texto sin stopwords, porque la puntuación, intensificadores y negaciones aportan información al sentimiento.

Tabla 7. Distribución e intensidad de sentimiento por clase

Clase	Negativos	Neutrales	Positivos	% negativo	Neg. media	Compound medio
target = 0	1,849	1,097	1,396	42.58%	0.1337	-0.0560
target = 1	1,880	855	536	57.47%	0.1765	-0.2669




Figura 10. Distribución global y proporción de sentimiento por target.




Figura 11. Negatividad y compound de VADER por clase.

La evidencia descriptiva responde afirmativamente a la pregunta central: los tweets sobre desastres reales tienden a ser más negativos. La tasa negativa aumenta de 42.58% a 57.47%; la negatividad media sube de 0.1337 a 0.1765; y el compound medio baja de -0.0560 a -0.2669. Las distribuciones se traslapan, por lo que el sentimiento no determina la clase, pero sí muestra una asociación consistente.

Tweets con mayor polaridad

Tabla 8. Diez tweets con compound más negativo

#	Tweet	Target	Compound
1	wreck? wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck? wreck wreck wreck?	0	-0.9883
2	@Abu_Baraa1 Suicide bomber targets Saudi mosque at least 13 dead - Suicide bomber targets Saudi mosque at...	1	-0.9686
3	Suicide bomber kills 15 in Saudi security site mosque - A suicide bomber killed at least 15 people in an...	1	-0.9623
4	? 19th Day Since 17-Jul-2015 -- Nigeria: Suicide Bomb Attacks Killed 64 People; Blamed: Boko Haram [L.A....	1	-0.9595
5	17 killed in Saudi Arabia mosque suicide bombing A suicide bomber attacked a mosque in Aseer south-western...	1	-0.9552
6	at the lake *sees a dead fish* me: poor little guy i wonder what happened ashley: idk maybe it drowned wtf...	0	-0.9549
7	illegal alien released by Obama/DHS 4 times Charged With Rape & Murder of Santa Maria CA Woman Had Prior...	1	-0.9538
8	Bomb Crash Loot Riot Emergency Pipe Bomb Nuclear Chemical Spill Gas Ricin Leak Violence Drugs Cartel Cocaine...	1	-0.9524
9	Bomb head? Explosive decisions dat produced more dead children than dead bodies trapped tween buildings on...	1	-0.9500
10	@cspan #Prez. Mr. President you are the biggest terrorist and trouble maker in the world. You create...	1	-0.9493

Tabla 9. Diez tweets con compound más positivo

#	Tweet	Target	Compound
1	Check out 'Want Twister Tickets AND A VIP EXPERIENCE To See SHANIA? CLICK HERE:' at http://t.co/3GEROQ49o1 I...	0	0.9730
2	@thoutaylorbrown I feel like accidents are just drawn to you but I'm happy you've survived all of them. Hope...	0	0.9564
3	Today's storm will pass; let tomorrow's light greet you with a kiss. Bask in this loving warmth; let your...	1	0.9471
4	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.	0	0.9423

5	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.	0	0.9423
6	Maaaaan I love Love Without Tragedy by @rihanna I wish she made the whole song	0	0.9394
7	Free Ebay Sniping RT? http://t.co/B231U11O1K Lumbar Extender Back Stretcher Excellent Condition!! ?Please...	0	0.9376
8	@Raishimi33 :) well I think that sounds like a fine plan where little derailment is possible so I applaud you :)	1	0.9356
9	I'm not a Drake fan but I enjoy seeing him body-bagging people. Great marketing lol.	0	0.9345
10	@duchovbutt @Starbuck_Scully @MadMakNY @davidduchovny yeah we survived 9 seasons and 2 movies. Let's hope for...	0	0.9344

Entre los diez tweets más negativos, ocho pertenecen a target = 1 y dos a target = 0. En los diez más positivos ocurre lo contrario: dos son desastres reales y ocho pertenecen a target = 0. Estos extremos apoyan la asociación general, pero los casos cruzados recuerdan que VADER mide tono, no veracidad ni relación causal con un desastre.

Variable de negatividad y modelo final

Prueba de aporte predictivo

Tabla 10. Efecto de incorporar la negatividad de VADER

Evaluación	Variables	F1	Cambio
Validación cruzada	Solo TF-IDF	0.7421	-
Validación cruzada	TF-IDF + negatividad	0.7380	-0.0041
Prueba	Solo TF-IDF	0.7772	-
Prueba	TF-IDF + negatividad	0.7723	-0.0050




Figura 12. Matrices de confusión con y sin la variable de negatividad.

La variable de negatividad no mejoró el desempeño. El F1 de validación cruzada disminuyó 0.0041 y en prueba bajó aproximadamente 0.0050. La explicación más probable es que TF-IDF ya representa palabras con carga negativa y que el sentimiento agrega información redundante o demasiado general. Por esta razón, el modelo final mantiene regresión logística con unigramas y excluye negatividad.

Función de clasificación

La función `clasificar_tweet(tweet)` recibe texto nuevo, aplica exactamente el mismo preprocesamiento, calcula VADER para informar sentimiento y construye el DataFrame esperado por el pipeline entrenado. Devuelve la clase, una descripción legible, la probabilidad de desastre cuando el clasificador la ofrece, la negatividad y la etiqueta de sentimiento. Esta separación permite ampliar el proyecto sin modificar el flujo principal.

Conclusiones

- El corpus etiquetado contiene 7,613 tweets y una distribución moderadamente desbalanceada: 57% en target = 0 y 43% en target = 1. test.csv aporta 3,263 filas sin etiqueta y no debe mezclarse con la evaluación.
- El preprocesamiento conservó señales relevantes de Twitter: URLs y menciones se reemplazaron por marcadores, los hashtags conservaron su palabra, los números se mantuvieron y las negaciones se excluyeron de las stopwords.

- Los unigramas muestran vocabulario temático en $\text{target} = 1$, mientras los bigramas recuperan expresiones más específicas como *suicide bomber* y *oil spill*. No obstante, añadir bigramas redujo ligeramente el F1.
- La mejor configuración según validación cruzada fue TF-IDF de unigramas con regresión logística. En prueba obtuvo accuracy 0.8227, precision 0.8441, recall 0.7202 y F1 0.7772.
- Los tweets de desastres reales presentan mayor negatividad según VADER, pero esa variable no mejoró la clasificación. El resultado demuestra que una variable puede ser descriptivamente relevante sin aportar valor incremental al modelo.

Limitaciones

El dataset contiene ubicaciones faltantes, textos duplicados y señales de codificación dañada. VADER es un método léxico y puede fallar con sarcasmo, contexto noticioso o significados figurados. Las métricas provienen de una sola partición final y una validación cruzada limitada; por tanto, no deben interpretarse como rendimiento garantizado fuera de la competencia. Finalmente, los coeficientes muestran asociaciones del corpus, no causas.

Repositorio

El proyecto se encuentra implementado en el siguiente [repositorio de GitHub](#).

[Link del documento](#) del informe.

Referencias

- Feinerer, I., Hornik, K., & Meyer, D. (2008). Text Mining Infrastructure in R. *Journal of Statistical Software*, 25(5), 1-54. <https://doi.org/10.18637/jss.v025.i05>
- Hutto, C. J., & Gilbert, E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. *Proceedings of ICWSM*.
- Jurafsky, D., & Martin, J. H. *Speech and Language Processing* (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>

Kaggle. Natural Language Processing with Disaster Tweets. <https://www.kaggle.com/competitions/nlp-getting-started>

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.